



Universidad Nacional Autónoma de México
Escuela Nacional de Estudios Superiores
Unidad Morelia



Tarea
Ejercicios sección 2.8.1

PRESENTA:
Luis Alberto García Orozco

PROFESOR:
Haydeé Peruyero

GRADO
Licenciatura en Tecnologías para la Información en Ciencias

Asignatura: Estadística Multivariada

A: 5 de octubre de 2025

Ejercicios:

Ejercicio 1: (R): Para el datasets `datasets::trees`, realice las pruebas de hipótesis (Usar la tabla de ANOVA para calcular el estadístico F_0 y encontrar el p-valor asociado usando `pf(F0, df1, df2, lower.tail = FALSE)`) para determinar si:

1. El modelo solo con la variable `Girth` es mejor que el modelo completo.

Análisis del modelo completo:

```
> mc = lm('Volume ~ .', datos)
> summary(mc)
Call:
lm(formula = "Volume ~ .", data = datos)

Residuals:
    Min       1Q   Median       3Q      Max
-6.4065 -2.6493 -0.2876  2.2003  8.4847

Coefficients:
              Estimate Std. Error t value Pr(>t)
(Intercept)  -57.9877     8.6382  -6.713 2.75e-07 ***
Girth          4.7082     0.2643  17.816 < 2e-16 ***
Height         0.3393     0.1302   2.607  0.0145 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.882 on 28 degrees of freedom
Multiple R-squared:  0.948,    Adjusted R-squared:  0.9442
F-statistic: 255 on 2 and 28 DF,  p-value: < 2.2e-16

> anov_mc = anova_table(mc); anov_mc
Fuente.de.Variacion Suma de cuadrados Grados de libertad
1          Regresion          7684.1625                2
2          Residuales          421.9214               28
3            Total          8106.0839               30
Cuadrados medios      F_0
1          3842.08126 254.9723
2           15.06862      NA
3              NA      NA
```

Análisis del modelo sin 'Height':

```
> m1 = lm('Volume ~ Girth', datos)
> summary(m1)

Call:
lm(formula = "Volume ~ Girth", data = datos)

Residuals:
    Min       1Q   Median       3Q      Max
-8.065 -3.107  0.152  3.495  9.587

Coefficients:
              Estimate Std. Error t value Pr(>t)
(Intercept) -36.9435     3.3651  -10.98 7.62e-12 ***
Girth         5.0659     0.2474   20.48 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.252 on 29 degrees of freedom
Multiple R-squared:  0.9353,    Adjusted R-squared:  0.9331
F-statistic: 419.4 on 1 and 29 DF,  p-value: < 2.2e-16

> anov_m1 = anova_table(m1); anov_m1
Fuente.de.Variacion Suma de cuadrados Grados de libertad
1      Regresion           7581.7813              1
2      Residuales           524.3025             29
3      Total              8106.0839             30
Cuadrados medios      F_0
1      7581.7813 419.3603
2      18.0794    NA
3      NA        NA
>
```

Observando los resultados de las pruebas F podemos ver que ambos modelos son significantes y con ayuda de la pruebas t también vemos que tanto 'Girth' es significativo en ambos modelos y 'Height' es apenas significativo para el modelo completo.

Análisis de anova entre modelos:

	Modelo	RES_GL	RSC	GL	Suma de Cuadrados	F value	pval
1	Completo	29	524.3025	NA	NA	NA	NA
2	Incompleto	28	421.9214	1	102.3812	6.79433	0.01449097

Aquí podemos observar que el p value de esta tabla de anova es de 0.01449 lo que nos indica el efectivamente el parámetro adicional 'Height' aporta al modelo, por lo tanto el modelo completo aporta más que el modelo con la variable 'Grith'.

2. El modelo sin Girth y Height es mejor que el completo.

Análisis del modelo vacío:

```
> m2 = lm('Volume ~ 1', datos)
> summary(m2)
Call:
lm(formula = "Volume ~ 1", data = datos)

Residuals:
    Min       1Q   Median       3Q      Max
-19.971 -10.771  -5.971   7.129  46.829

Coefficients:
              Estimate Std. Error t value Pr(>t)
(Intercept)   30.171      2.952   10.22 2.75e-11 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 16.44 on 30 degrees of freedom
> anov_m2 = anova_table(m2); anov_m2
Fuente.de.Variacion Suma de cuadrados Grados de libertad
1          Regresion      -3.637979e-12              0
2          Residuales      8.106084e+03             30
3            Total      8.106084e+03             30
Cuadrados medios  F_0
1              -Inf -Inf
2          270.2028   NA
3              NA   NA
```

Comparación de modelos:

```
> anova_table(m2, mc)
Modelo RES_GL      RSC GL Suma de Cuadrados  F value pval
1  Completo    30 8106.0839 NA              NA      NA  NA
2 Incompleto   28  421.9214  2          7684.163 254.9723    0
```

Aquí podemos observar que el p value de esta tabla de anova es de 0 lo que nos indica fuertemente que el modelo completo es mucho más significativo para la descripción de estos datos que el modelo vacío.

Ejercicio 2: (Python): Para el dataset de marketing, realice las pruebas de hipótesis utilizando la tabla de ANOVA sobre:

1. Uno de los parámetros, justificar cual.

Veamos el resultado de la tabla anova completa del modelo completo:

```
mc = LinearModel('sales', ['youtube', 'facebook', 'newspaper'], df)
print(mc.anov_t.iloc[:,3])
print(mc.anov_t.iloc[:,3:])
```

	Fuente de variacion	Suma de cuadrados	Grados de libertad
0	youtube	4773.050160	1
1	facebook	2225.687908	1
2	newspaper	0.127753	1
3	Regresion	6998.865821	3
4	Residuales	801.828379	196
5	Total	7800.694200	199
	Cuadrados medios	F_0	p_value
0	4773.050160	1166.730757	0.0
1	2225.687908	544.050126	0.0
2	0.127753	0.031228	0.859914
3	2332.955274	570.270704	0.0
4	4.090961	<NA>	<NA>
5	39.199468	<NA>	<NA>

Por los valores de los estadísticos F_0 y los p values, podemos observar que la variable que más aporta y por mucho es la de youtube, por lo tanto el modelo al que le harémos prueba de anova será el siguiente:

```
m1 = LinearModel('sales', ['youtube'], df)
print(m1.anov_t.iloc[:,3])
print(m1.anov_t.iloc[:,3:])
```

	Fuente de variacion	Suma de cuadrados	Grados de libertad
0	youtube	4773.05016	1
1	Regresion	4773.05016	1
2	Residuales	3027.64404	198
3	Total	7800.69420	199
	Cuadrados medios	F_0	p_value
0	4773.050160	312.144994	0.0
1	4773.050160	312.144994	0.0
2	15.291132	<NA>	<NA>
3	39.199468	<NA>	<NA>

2. Todos los parámetros.

Solo repetimos lo del principio:

```
mc = LinearModel('sales', ['youtube', 'facebook', 'newspaper'], df)
print(mc.anov_t.iloc[:,3])
print(mc.anov_t.iloc[:,3:])
```

	Fuente de variacion	Suma de cuadrados	Grados de libertad
0	youtube	4773.050160	1
1	facebook	2225.687908	1
2	newspaper	0.127753	1
3	Regresion	6998.865821	3
4	Residuales	801.828379	196
5	Total	7800.694200	199
	Cuadrados medios	F_0	p_value
0	4773.050160	1166.730757	0.0
1	2225.687908	544.050126	0.0
2	0.127753	0.031228	0.859914
3	2332.955274	570.270704	0.0
4	4.090961	<NA>	<NA>
5	39.199468	<NA>	<NA>

3. Un subconjunto de parámetros, justificar cual.

Por lo visto anteriormente con los estadísticos F_0 y los p values podemos determinar que la variable que menos aporta es newspaper, por lo tanto hacemos el siguiente modelo y la tabla anova:

```
m2 = LinearModel('sales', '.', df, minus = ['newspaper'])
print(m2.anov_t.iloc[:,3])
print(m2.anov_t.iloc[:,3:])
```

	Fuente de variacion	Suma de cuadrados	Grados de libertad
0	youtube	4773.050160	1
1	facebook	2225.687908	1
2	Regresion	6998.738069	2
3	Residuales	801.956131	197
4	Total	7800.694200	199
	Cuadrados medios	F_0	p_value
0	4773.050160	1172.496655	0.0
1	2225.687908	546.738781	0.0
2	3499.369034	859.617718	0.0
3	4.070843	<NA>	<NA>
4	39.199468	<NA>	<NA>

Ahora hagamos la comparación de modelos:

```
> a0 = anova_between_lm(m2,m1)
> print(a0.iloc[:,4])
> print(a0.iloc[:,4:])
```

	Modelo	Grados de libertad	Suma de cuadrados	Suma de Cuadrados
0	Completo	198	3027.644040	<NA>
1	Reducido	197	801.956131	2225.687908
	F_0	p_value		
0	<NA>	<NA>		
1	546.738781	0.0		

```
> a1 = anova_between_lm(m1,mc)
> print(a1.iloc[:,4])
> print(a1.iloc[:,4:])
```

	Modelo	Grados de libertad	Suma de cuadrados	Suma de Cuadrados
0	Completo	198	3027.644040	<NA>
	F_0	p_value		
1	Reducido	196	801.828379	2225.815661
0	<NA>	<NA>		
1	272.040677	0.0		

Recordando que mc es el modelo completo, $m1 = mc - \text{newspaper}$ y $m2 = m1 - \text{facebook}$ = $mc - \text{newspaper} - \text{facebook}$, notemos que los p values de las pruebas anteriores nos indican que m1 es mejor que m2, y que mc es mejor que m1, lo que significa q apesar de que newspaper no resultara tan significativo con respecto a las demás variables, sigue siendo significativo.